ngram 实验报告

olhwdb2

实验结果

方法	WER
baseline	6.34
stupid-backoff	5.50
ngram-max	6.58
ngram-mean	6.58
我们的方法	4.87

参数设定

这里使用的都是5-gram模型。输出分数与原识别置信度通过一定比例结合,有 $\alpha*P_{rec}+\beta*P_{lm}$ 。其中 P_{rec} 为识别模型输出的置信度; P_{lm} 为语言模型输出的分数, $\alpha=0.68$ 。

baseline

不加入语言模型,即识别结果直接输出

stupid-backoff

ngram经典匹配方法,即从长到短寻找匹配项,输出最长的可匹配项的分数。

ngram-max

与stupid-backoff相似,但是输出的不是最长可匹配项的分数,而是最大的分数。

ngram-mean

输出从最长到最短所有分数的平均值。

我们的方法

通过判断当前字与前向字是否能组合成一个词,来找到当前字的最佳分割点,输出组合后的词的分数。

bad case

BASELINE	我们的方法	GROUNDTRUTH
改变3	改变3	改变了
官光经济	官光经济	宏观经济
拒绝杀访	拒绝杀访	拒绝采访
降水过程	降水过程	降雨过程
Harmony	Hororony	Harmony

可以看出:

- 1. 存在数字改错的问题
- 2. 词首难以改正,较为依赖识别模型
- 3. 中间能组合成词的很难改对
- 4. 英文上还有些问题

除此之外,标点符号上也存在一些问题,目前难以改对。